

Comparaison de fréquences

I – Test du χ^2

1 – χ^2 d'ajustement = d'adéquation = de conformité

Objectifs :

- comparer des fréquences observées à des fréquences théoriques

H_0 : effectifs observés conformes à distribution théorique

H_1 : effectifs observés non conformes à distribution théorique

Sous H_0 :

C_i (calculés) et O_i (observés)

Si $C_i \geq 5$: $\chi_c^2 = \sum_{i=1}^n \frac{(O_i - C_i)^2}{C_i}$

α

χ_{table}^2

$v = (n-1)$ ddl

Comparaison :

- Si $\chi_c^2 > \chi_t^2$: au risque α , on rejette H_0 : non-conformité
- Si $\chi_c^2 < \chi_t^2$: au risque α , on accepte H_0 : on ne montre pas de différence significative entre la distribution observée et la distribution théorique

Exercice 1 :

Mendel → croise des fleurs blanches et rouges :

$n = 100$

22 rouges

Rappel : loi de Mendel $\frac{1}{4}$ $\frac{1}{2}$ $\frac{1}{4}$

46 roses

32 blanches

Sous H_0 , C_i :		Rouges	Roses	Blanches
	O_i	22	46	32
	C_i	25	50	25

$C_i \geq 5$ donc :

$$\chi_c^2 = \frac{(22-25)^2}{25} + \frac{(46-50)^2}{50} + \frac{(32-25)^2}{25} = \frac{9}{25} + \frac{16}{50} + \frac{49}{25} = \frac{132}{50} = 2,64$$

$\alpha = 5\%$

$v = (3-1) = 2$ ddl

$\chi_t^2 = 5,99$

$\chi_c^2 < \chi_t^2$: au risque 5%, on accepte H_0 : on ne montre pas que la distribution observée ne suit pas la loi de Mendel

Exercice 2 :

Même problème mais n = 400

	Rouges	Roses	Blanches
O _i	88	184	128
C _i	100	200	100

$$\chi_c^2 = \frac{(88-100)^2}{100} + \frac{(184-200)^2}{200} + \frac{(128-100)^2}{100} = 10,56$$

 $\chi_c^2 > \chi_t^2$: au risque 5%, on rejette H_0 : la distribution observée ne suit pas la loi de Mendel
2 – χ^2 d'homogénéité = d'indépendance**Objectifs :**

- à utiliser quand plusieurs variables qualitatives
- homogénéité de 2 traitements ? (=indépendance ?)
- effectifs observés comparés entre eux (pas de comparaison de pourcentages)

Exemple :

2 échantillons A, B

G = guéris

	G	\bar{G}
A	n_1	n_2
B	n_3	n_4

	G	Amélioration	Stabilité	Aggravation
A				
B				
C				

Tableau : lignes x colonnes

$$C_i = \frac{T_l \times T_c}{T_g} \quad \text{avec } T_l : \text{total ligne ; } T_c : \text{total colonne ; } T_g : \text{total grille}$$

	G		\bar{G}		Total
	O _i	C _i	O _i	C _i	
A	45	38,33	55	61,67	100
B	70	76,67	130	123,33	200
Total	115	115	185	185	300

Sous H_0 , C_i = effectif théorique guéri avec le traitement A ou B

$$\chi_c^2 = \sum_{i=1}^n \frac{(O_i - C_i)^2}{C_i} = \frac{(45-38,33)^2}{38,33} + \frac{(55-61,67)^2}{61,67} + \frac{(70-76,67)^2}{76,67} + \frac{(130-123,33)^2}{123,33} = 2,82$$

 $\alpha = 5\%$ $v = (l-1)(c-1) = (ligne-1)(colonne-1) = (2-1)(2-1) = 1$ ddl(pour les colonnes, O_i et C_i ne comptent que pour 1 colonne et non 2) $\chi_t^2 = 3,84$ $\chi_c^2 < \chi_t^2$: au risque 5%, on accepte H_0 donc on ne montre pas de différence significative

Exercice :

3 groupes A, B, C atteints de leucémie aiguë

3 traitements différents 1, 2 et 3

Observation des symptômes

traitement délai	1		2		3		
	O _i	C _i	O _i	C _i	O _i	C _i	
< 1 mois	35	38,5	41	37,7	36	25,8	112
1 à 1,9 mois	16	20,3	17	19,9	26	18,8	59
2 à 3,9 mois	18	17,9	17	17,5	17	16,6	52
4 à 7,9 mois	20	14,8	17	14,5	6	13,7	43
≥ 8 mois	9	6,5	4	6,4	6	6,1	19
	98		96		91		285

H_0 : pas de différence de délai selon le traitement

H_1 : il existe une différence de délai

C_i : efficacité théorique si délai :

$$C_{11} = \frac{112 \times 98}{285} = 38,5$$

$$C_{12} = \frac{112 \times 96}{285} = 37,7$$

C_i doit être plus grand que 5 (pas d'importance par contre pour les O_i) donc on regroupe les données pour que tous les C_i ≥ 5.

Calcul du χ^2 :

$$\chi^2 = \frac{\sum_{i=1}^n (O_i - C_i)^2}{C_i} = 13,17$$

$$\alpha = 5\%$$

$$v = (I-1)(C-1) = 4 \times 2 = 8 \text{ ddl}$$

$$\chi^2_t = 15,51$$

$\chi^2 < \chi^2_t$: au risque 5%, on accepte H_0 , on ne montre pas de différence significative

3 – χ^2 corrigé de Yates (pour tableaux 2l x 2c)

Si C_i < 5 :

- regrouper les effectifs observés, si cela ne change rien au problème posé
- corrigé de Yates : χ^2 surestimé

$$\chi^2_{\text{corrigé}} = \frac{\sum [|O_i - C_i| - \frac{1}{2}]^2}{C_i}$$

Exemple :

$n = 20$ souris traitées, 8 tumeurs (40%)

en théorie, 20% de tumeurs dans la population \mathcal{P}

	T	\bar{T}	
O_i	8	12	20
C_i	4	16	20

H_0 : le traitement ne modifie pas le taux de tumeurs

H_1 : le traitement modifie le taux de tumeurs

$$\chi^2_c = \frac{(|18-4|-0,5)^2}{4} + \frac{(|12-16|-0,5)^2}{16} = 3,83$$

$\alpha = 5\%$

$v = 1$ ddl

$\chi^2_t = 3,84$

$\chi^2_c < \chi^2_t$: au risque 5%, on accepte H_0 , on ne montre pas de différence significative

II – Test de l'écart-réduit

1 – Comparer fréquence observée et fréquence théorique

p_0 n
 p population
 ↙
 fréquence connue

H_0 : pas de différence significative

H_1 : il existe une différence significative

Sous H_0 :

Si np et $nq \geq 5$ ($p + q = 1$), $U_c = \frac{p_0 - p}{\sqrt{\frac{pq}{n}}}$ suit une loi normale $\mathcal{N}(0 ; 1)$

α, U_t

Comparaison :

- Si $|U_c| > U_t$: au risque α , on rejette H_0 , on accepte H_1
- Si $|U_c| < U_t$: au risque α , on accepte H_0 : on ne montre pas de différence significative

2 – Comparer 2 fréquences observées

p_A n_A
 p_B n_B

H_0 : pas de différence significative

H_1 : il existe une différence significative

Sous H_0 :

Si $n_A p$, $n_A q$, $n_B p$, $n_B q \geq 5$, alors $p = \frac{n_A p_A + n_B p_B}{n_A + n_B}$ (et $q = 1 - p$)

et $U_c = \frac{p_A - p_B}{\sqrt{\frac{pq}{n_A} + \frac{pq}{n_B}}}$ suit une loi normale $\mathcal{N}(0 ; 1)$

alfa, U_t

Comparer $|U_c|$ et U_t

3 – Exercices

Exercice 1 :

Population 50% ♂, 50% ♀

$n = 20$ 4 ♂, 16 ♀ touchés par la maladie

La maladie est-elle en rapport avec le sexe ?

$$p_0 = \frac{16}{20} = 0,8$$

$$p = 0,5$$

$$\left. \begin{array}{l} np = 10 \\ nq = 10 \end{array} \right\} \text{ test de l'écart-réduit}$$

H_0 : la maladie touche autant de filles que de garçons

H_1 : la maladie touche différemment les filles et les garçons

Sous H_0 :

$$U_c = \frac{p_0 - p}{\sqrt{\frac{pq}{n}}} = \frac{-0,8 + 0,5}{\sqrt{\frac{0,5 \times 0,5}{20}}} = 2,68$$

$$\alpha = 5\% \rightarrow U_t = 1,96$$

$|U_c| > U_t$: au risque 5%, on rejette H_0 , la maladie touche plus les ♀ que les ♂

Test du χ^2 :

$$\chi_c^2 = 2,68^2 = U_c^2$$

	♀	♂	
Oi	16	4	20
Ci	10	10	20

$$\chi_c^2 = \frac{(16-10)^2}{10} + \frac{(4-10)^2}{10} = 7,2$$

$$\alpha = 5\% \rightarrow \chi_t^2 = 3,84$$

$\chi_c^2 > \chi_t^2$: au risque 5%, on rejette H_0

Exercice 2 :

$n = 927$ enfants malades

$408 \bar{T} \rightarrow 104$ complications $\rightarrow 304$ sans complications

$519 T \rightarrow 166$ complications $\rightarrow 353$ sans complications

Est-ce que le traitement est efficace ?

$$n_A = 408 \quad p_A = \frac{104}{408} = 0,255$$

$$n_B = 519 \quad p_B = \frac{166}{519} = 0,320$$

H_0 : la fréquence de complication est la même avec ou sans traitement

H_1 : la fréquence de complication est différente avec ou sans traitement

Sous H_0 :

$$U_C = \frac{p_A - p_B}{\sqrt{\frac{pq}{n_A} + \frac{pq}{n_B}}} = -2,16$$

$$\alpha = 5\% \rightarrow U_t = 1,96$$

$|U_C| > U_t$: au risque 5%, on rejette H_0 , il existe une différence de fréquence de complication avec ou sans traitement

Autre méthode : test X^2 (homogénéité)

	C		\bar{C}		
	Oi	Ci	Oi	Ci	
T	166	157,16	353	357,83	519
\bar{T}	104	118,83	304	289,16	408
	270		657		927

$$X_C^2 = 4,67$$

$$\alpha = 5\% \rightarrow X_t^2 = 3,84$$

$X_C^2 > X_t^2$: au risque 5%, on rejette H_0 , il existe une différence de fréquence de complication avec ou sans traitement

III – Test de Mac-Nemar

Variables qualitatives, résultats sur même sujet avant et après traitement donc pas indépendants.

	avant		
après		positif	négatif
positif		n_1	n_2
négatif		n_3	n_4

N = nombre total de patients = $n_1 + n_2 + n_3 + n_4$

2 fréquences non comparables directement, puisque même personne avant et après traitement.

H_0 : pas de différence significative entre les fréquences

H_1 : il existe une différence significative entre les fréquences

fréquences (+,-) (-,+) théoriques de 0,5

↙ ↘
+avt, -après -avt, +après

$$\frac{n_2}{n_2+n_3} \quad \text{ou} \quad \frac{n_3}{n_2+n_3}$$

$$U_c = \frac{\frac{n_2}{n_2+n_3} - 0,5}{\sqrt{\frac{0,5 \times (1-0,5)}{n_2+n_3}}} = \frac{n_2 - n_3}{\sqrt{n_2+n_3}}$$

$$\alpha = 5\% \rightarrow U_t = 1,96$$

Comparaison :

- Si $|U_c| > U_t$: au risque α , on rejette H_0 donc le traitement est efficace
- Si $|U_c| < U_t$: au risque α , on accepte H_0

Test avec X^2 :

Oi	n_2	n_3
Ci	$\frac{n_2+n_3}{2}$	$\frac{n_2+n_3}{2}$

$$X_c^2 = \frac{(n_2 - \frac{n_2+n_3}{2})^2}{\frac{n_2+n_3}{2}} + \frac{(n_3 - \frac{n_2+n_3}{2})^2}{\frac{n_2+n_3}{2}} = \frac{(n_2 - n_3)^2}{(n_2 + n_3)}$$

$$X_t^2 \rightarrow \alpha, v = 1 \text{ ddl}$$

$$X_c^2 = U_c^2$$

Exemple :

Patients asthmatiques

Test d'un aérosol

Etude de la gêne respiratoire

Effectifs dépendants : pas X^2

Pas de gêne avant, pas de gêne après = 30

Pas de gêne avant, gêne après = 12

Gêne avant, pas de gêne après = 40

Gêne avant, gêne après = 18

=

	avant	gêne	pas gêne
après			
gêne		18	12
pas gêne		40	30

$$U_c = \frac{12-40}{\sqrt{12+40}} = -3,88$$

$$U_t = 1,96$$

ou

$$X_c^2 = \frac{(12-40)^2}{12+40} = 15,08$$

$$X_t^2 = 3,84$$

$\left. \begin{array}{l} |U_c| > U_t \\ X_c^2 > X_t^2 \end{array} \right\}$ au risque 5%, on rejette H_0 , il existe une différence avec ou sans traitement => efficacité