

# Comparaison de moyennes

## I – Comparer une moyenne à une valeur donnée

### 1 – Test de statistique

Echantillon E de taille n  
de moyenne m  
de variance  $s^2$

Population  $\mathcal{P}$  de moyenne  $\mu$

**Question :** l'échantillon E provient-il de la population  $\mathcal{P}$  ? = Existe-t-il une différence significative entre m et  $\mu$  ?

**Hypothèses :**

$H_0$  : hypothèse nulle = E provient de  $\mathcal{P}$

$H_1$  : hypothèse alternative = E ne provient pas de  $\mathcal{P}$

### a – Comment faire un test statistique ?

1. Choisir le risque  $\alpha$  = risque de première espèce, c'est le risque de rejeter  $H_0$  alors que  $H_0$  est vraie. Généralement  $\alpha = 5\%$ , parfois  $\alpha = 1\%$
2. Poser  $H_0$  et  $H_1$
3. Sous  $H_0$ , on calcule un paramètre ( $U_c$ ) dont on connaît la distribution, pour pouvoir comparer m et  $\mu$  :

$$U_c = \frac{m - \mu}{\frac{s}{\sqrt{n}}}$$

4. Chercher dans la table  $U_\alpha$
5. Comparer  $|U_c|$  et  $U_\alpha$  :
  - Si  $|U_c| > U_\alpha$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$
  - Si  $|U_c| < U_\alpha$  : au risque  $\alpha$  on accepte  $H_0$

### 1 – Pour les grands échantillons ( $n \geq 30$ )

**Si on connaît m,  $s^2$ ,  $\mu$  :**

$H_0$  : il n'existe pas de différence significative entre l'échantillon et la population

$H_1$  : il existe une différence significative entre l'échantillon et la population

Sous  $H_0$  :  $U_c = \frac{m - \mu}{\frac{s}{\sqrt{n}}}$  suit une loi normale

Si  $\alpha = 5\%$ ,  $U_t = 1,96$  / Si  $\alpha = 1\%$ ,  $U_t = 2,57$

**Comparaison :**

- Si  $|U_c| > U_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$
- Si  $|U_c| < U_t$  : au risque  $\alpha$  on accepte  $H_0$  (sans certitude que  $H_0$  est vraie), donc on ne met pas en évidence une différence significative

**Si on connaît l'écart-type  $\sigma$  de  $\mathcal{P}$  :**

Même procédure sauf que  $U_c = \frac{m - \mu}{\frac{\sigma}{\sqrt{n}}}$

**2 – Pour les petits échantillons ( $n < 30$ )**

**Si on connaît  $\sigma$  :** cf. grands échantillons

**Si  $\sigma$  inconnu :**

Sous  $H_0$ ,  $t_c = \frac{m - \mu}{\frac{s}{\sqrt{n}}}$  suit une loi de Student à  $(n-1)$  ddl (degré de liberté)

On trouve le  $t_t$  dans la table de Student

**Comparaison :**

- Si  $|t_c| > t_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$
- Si  $|t_c| < t_t$  : au risque  $\alpha$  on accepte  $H_0$

**b – Exemple**

On mesure le temps de réaction chez des souris exposées à une stimulation au médicament X.

$$\mu = 23,7 \text{ s}$$

$$n = 100$$

$$m = 22,9 \text{ s}$$

$$s^2 = 13,98 \text{ s}^2$$

1. Est-ce que le médicament X modifie le temps de réaction des souris ?
2. Pour  $n=16$  ?

1.  $H_0$  = le médicament ne modifie pas le temps de réaction

$H_1$  = le médicament modifie le temps de réaction

Sous  $H_0$  :

$$U_c = \frac{m - \mu}{\frac{s}{\sqrt{n}}} = \frac{22,9 - 23,7}{\frac{\sqrt{13,98}}{\sqrt{100}}} = -2,14$$

$$\alpha = 5\% \rightarrow U_t = 1,96$$

$|U_c| > U_t$  : au risque 5%, on rejette  $H_0$ , donc le médicament modifie le temps de réaction.

2.  $n=16$ ,  $H_0$  et  $H_1$  sont les mêmes

Sous  $H_0$  :

$$t_c = \frac{m - \mu}{\frac{s}{\sqrt{n}}} = \frac{22,9 - 23,7}{\frac{\sqrt{13,98}}{\sqrt{16}}} = -0,86$$

$$\alpha = 5\% \text{ et } \text{ddl} = (n-1) = (16-1) = 15 \rightarrow t_t = 2,13$$

$|t_c| < t_t$  : au risque 5%, on accepte  $H_0$ , donc on ne montre pas que le médicament modifie le temps de réaction.

## II – Comparer les moyennes observées sur des échantillons indépendants

### 1 – Deux grands échantillons

$E_1 : m_1, s_1^2, n_1$

$E_2 : m_2, s_2^2, n_2$

$\mathcal{P} : \mu$

**Si  $n_1$  et  $n_2 \geq 30$  :**

- $H_0$  : les 2 échantillons sont de la même population, il n'y a pas de différence significative entre les 2 moyennes
- $H_1$  : les 2 échantillons ne sont pas de la même population, il existe une différence significative entre les 2 moyennes

Sous  $H_0$ ,

$m_1$  et  $m_2$  suivent une loi normale  $\mathcal{N}(\mu ; \frac{\sigma^2}{n})$

$m_1$  suit une loi normale  $\mathcal{N}(\mu ; \frac{s_1^2}{n_1})$

$m_2$  suit une loi normale  $\mathcal{N}(\mu ; \frac{s_2^2}{n_2})$

$d = m_1 - m_2$

$E(d) = \mu - \mu = 0$

$s_d^2 = \frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}$

$U = \frac{d-0}{s_d}$  suit une loi  $\mathcal{N}(0 ; 1)$  d'où  $U_c = \frac{m_1 - m_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$

Soit  $\alpha = 5\% \rightarrow U_t = 1,96$

Comparaison :

- Si  $|U_c| > U_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$  : les 2 moyennes proviennent de 2 populations différentes, il existe une différence significative entre les 2 moyennes
- Si  $|U_c| < U_t$  : au risque  $\alpha$  on accepte  $H_0$

### Exemple

Poids des nouveau-nés dans une maternité :

♂  $n_1 = 41$   $m_1 = 3,4$  kg  $s_1 = 0,385$  kg

♀  $n_2 = 65$   $m_2 = 3,36$  kg  $s_2 = 0,363$  kg

$H_0, H_1$

Sous  $H_0$  :

$$U_c = \frac{m_1 - m_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} = \frac{3,4 - 3,36}{\sqrt{\frac{0,385^2}{41} + \frac{0,363^2}{65}}} = 0,54$$

$\alpha = 5\% \rightarrow U_t = 1,96$

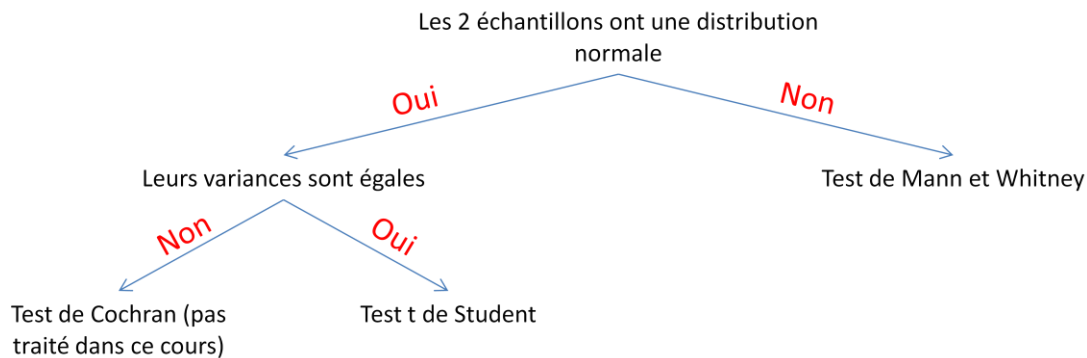
$|U_c| < U_t$  : au risque 5%, on ne montre pas de différence significative entre les poids des nnés ♂ et ♀

## 2 – Deux petits échantillons

2 échantillons :

$$E_1 : m_1, s_1^2, n_1$$

$$E_2 : m_2, s_2^2, n_2$$



### a – Les deux échantillons ont une distribution normale

On compare alors les variances :

$H_0$  : égalité des variances

$H_1$  : inégalité des variances

Test de Snédécour ou test F :

Paramètre  $F_c = \frac{S_1^2}{S_2^2}$  si  $s_1 > s_2$  ou  $F_c = \frac{S_2^2}{S_1^2}$  si  $s_1 < s_2$

Sous  $H_0$  et  $\alpha = 5\% \rightarrow p = \alpha/2 = F_T$

Table de Snédécour :

$v_1$  = nombre ddl au numérateur :  $(n_1 - 1)$  si  $s_1 > s_2$  ou  $(n_2 - 1)$  si  $s_1 < s_2$

$v_2$  = nombre ddl au dénominateur :  $(n_2 - 1)$  si  $s_1 > s_2$  ou  $(n_1 - 1)$  si  $s_1 < s_2$

Comparaison :

- Si  $F_c > F_T$  : au risque  $\alpha$  on rejette  $H_0$  donc les variances ne sont pas égales  $\rightarrow$  test de Cochran
- Si  $F_c < F_T$  : au risque  $\alpha$  on accepte  $H_0$  donc les variances sont égales  $\rightarrow$  test T de Student

1 – Les variances ne sont pas égales

On s'arrête là, on ne sait pas faire après.

2 – Les variances sont égales, on compare les moyennes

Il faut trouver une variance commune (puisqu'elles sont égales) :  $s^2$  commune.

$$s^2 = \frac{(n_1 - 1) s_1^2 + (n_2 - 1) s_2^2}{n_1 + n_2 - 2}$$

$H_0$  : pas de  $\neq$  significative entre les moyennes = les échantillons proviennent de la même population

$H_1$  : il existe une  $\neq$  significative entre les moyennes = les 2 échantillons proviennent de populations  $\neq$

Sous  $H_0$  :

$$t_c = \frac{m_1 - m_2}{\sqrt{\frac{s^2}{n_1} + \frac{s^2}{n_2}}} = \frac{m_1 - m_2}{s \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \text{ suit une loi de Student à } (n_1 + n_2 - 2) \text{ ddl}$$

On pose  $\alpha$  et  $t_t$  à  $(n_1 + n_2 - 2)$  ddl

**Comparaison :**

- Si  $|t_c| > t_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$  : il existe une différence significative entre les moyennes
- Si  $|t_c| < t_t$  : au risque  $\alpha$  on accepte  $H_0$  : on ne montre pas de différence significative entre les moyennes

## b – Les 2 échantillons n’ont pas une distribution normale : test non paramétrique de Mann et Whitney (rangs : *distribution free*)

### Exemple :

Comparaison des notes obtenues aux tests psychomoteurs pour des patients atteints par la maladie A ou par la maladie B.

Maladie A : 48, 60, 42, 58, 50, 31, 42  $n_A = 7$

Maladie B : 31, 41, 23, 28, 42  $n_B = 5$

$H_0$  : pas de différence significative

$H_1$  : il existe une différence significative

On classe les données par ordre croissant :

A =			31		42, 42	48	50	58	60
B =	23	28	31	41	42				

Rangs : 1	2	3,5	5	7	9	10	11	12
-----------	---	-----	---	---	---	----	----	----

$$T_A = 3,5 + 7 \times 2 + 9 + 10 + 11 + 12 = 59,5$$

$$T_B = 1 + 2 + 3,5 + 5 + 7 = 18,5$$

Pour vérifier si on n’a pas fait d’erreur, on calcule  $T_A + T_B$  et ça doit être égal à  $\frac{(n_A + n_B)(n_A + n_B + 1)}{2}$ .

**Paramètres :**

$$U_A = n_A \times n_B + \frac{n_A(n_A + 1)}{2} - T_A = 3,5 \quad \text{et} \quad U_B = n_A \times n_B + \frac{n_B(n_B + 1)}{2} - T_B = 31,5$$

$$1 - \text{Si } n_A \text{ ou } n_B < 10$$

$$U_C = \min(U_A; U_B) \text{ (ici, } U_A)$$

$$\text{Table : } n = \min(n_A; n_B)$$

$$m = \max(n_A; n_B)$$

$$\text{Ici : } n = 5, \quad m = 7, \quad m - n = 2, \quad \alpha = 5\%$$

**Comparaison :**

- Si  $|U_C| < U_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$  : il existe une différence significative
- Si  $|U_C| > U_t$  : au risque  $\alpha$  on accepte  $H_0$  : on ne montre pas de différence significative

Ici,  $U_C = 3,5$   $U_t = 5 \rightarrow U_C < U_t$  : au risque 5%, on rejette  $H_0$  : il existe une différence significative

2 – Si  $n_A$  et  $n_B \geq 10$ 

On montre que  $U_A$  et  $U_B$  suivent une loi normale  $\mathcal{N}\left(\frac{(n_A \cdot n_B)}{2} ; \frac{(n_A \cdot n_B)(n_A + n_B + 1)}{12}\right)$ .

$$U_C = \frac{U_A - \frac{n_A \cdot n_B}{2}}{\sqrt{\frac{n_A \cdot n_B (n_A + n_B + 1)}{12}}} \quad \text{ou} \quad U_C = \frac{U_B - \frac{n_A \cdot n_B}{2}}{\sqrt{\frac{n_A \cdot n_B (n_A + n_B + 1)}{12}}} \quad \text{selon que } U_A < U_B \text{ ou non.}$$

On pose  $\alpha$ ,  $U_t$

**Comparaison :**

- Si  $|U_C| > U_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$  : il existe une différence significative
- Si  $|U_C| < U_t$  : au risque  $\alpha$  on accepte  $H_0$  : on ne montre pas de différence significative

## c – Exercice

N° ampoule	1	2	3	4
Ø induration	10	13	13	7
	11	13	13	11
	11	14	14	12
	13	18	19	13
	14	18	22	13
	15	21		14
	17			

					Totaux
$n_i$	8	7	6	7	28
$\sum x_{ij}$	103	111	98	82	394
$m_i$	12,87	15,86	18,33	11,71	
$(\sum x_{ij})^2$	10 609	12 321	9 604	6 724	
$\frac{(\sum x_{ij})^2}{n_i}$	1 326,12	1 760,14	1 600,66	960,57	5 647,49
$\sum x_{ij}^2$	1 365	1 819	1 668	992	5 844

$$M = \frac{8 \cdot 12,87 + 7 \cdot 15,86 + \dots}{28} = \frac{394}{28} = 14,07$$

$$\begin{aligned} \sum_{i=1}^4 n_i (m_i - M)^2 &= \sum_{i=1}^4 \frac{(\sum x_{ij})^2}{n_i} - MN^2 \\ &= 5 647,49 - \frac{(\sum x_{ij})^2}{N} \\ &= 5 647,49 - \frac{394^2}{28} \\ &= 103,39 \end{aligned}$$

$$\begin{aligned} \sum_i \sum_j (x_{ij} - m_i)^2 &= \sum_i [\sum_j x_{ij}^2 - n_i m_i^2] \\ &= 5 844 - 5 647,49 \\ &= 196,51 \end{aligned}$$

$$1^{\text{e}} \text{ estimation} = \frac{196,51}{24} = 8,19$$

$$2^{\text{e}} \text{ estimation} = \frac{103,35}{4-1} = 34,45$$

$$\Rightarrow F_C = \frac{34,45}{8,19} = 4,2$$

$$\alpha = 2\% \rightarrow p = 1\%$$

$$F_T = 4,72$$

$$v_1 = 3 \text{ ddl}$$

$$v_2 = 24 \text{ ddl}$$

$F_C < F_T$  : au risque 2%, on ne montre pas de différence significative entre les vaccins.

### III – Séries appariées

#### 1 – Test paramétrique t

$d_i$  = différence entre valeur mesurée avant et après un traitement

TA = tension artérielle

Patients :	1	2	3	4	5	...	N
TA avant :	18	16	15	...			
TA après :	16	17	14	...			
Différence :	2	-1	1	...			

} Pas indépendantes car réalisées sur mêmes patients

$$\text{Différence moyenne : } \bar{d} = \frac{\sum d_i}{N}$$

$$s_d^2 = \frac{\sum d_i^2}{N-1} - \frac{(\sum d_i)^2}{N(N-1)}$$

$H_0$  : pas de différence significative entre TA avant et TA après

$H_1$  : il existe une différence significative

Sous  $H_0$  :

$$t_c = \frac{\bar{d} - 0}{\frac{s_d}{\sqrt{n}}}$$

suit une loi de Student à (N-1) ddl :

- si  $N \geq 30$
- si  $N < 30$  mais  $d_i$  suivent une loi Normale
- sinon : Wilcoxon

$\alpha$

**Comparaison :**

- Si  $|t_c| > t_t$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$  : il existe une différence significative
- Si  $|t_c| < t_t$  : au risque  $\alpha$  on accepte  $H_0$  : on ne montre pas de différence significative

#### 2 – Test de Wilcoxon

$H_0, H_1$

Calculer les  $d_i$

$|d_i|$  : les classer par ordre croissant en éliminant les  $d_i = 0$ , et leur donner des rangs

$R^+$  : somme des rangs des  $d_i > 0$

$R^-$  : somme des rangs des  $d_i < 0$

$N'$  : nombre des  $d_i$  non nuls

**Si  $N' \leq 25 \rightarrow$  table de Wilcoxon**

R table

 $\alpha$ **Comparaison :**

- Si  $R_{\text{table}} > \min(R^+; R^-)$  : au risque  $\alpha$  on rejette  $H_0$  et on accepte  $H_1$  : il existe une différence significative
- Si  $R_{\text{table}} < \min(R^+; R^-)$  : au risque  $\alpha$  on accepte  $H_0$  : on ne montre pas de différence significative

**Si  $N' > 25$  :***On ne sait pas faire.***3 – Exercice**

Patient	Antalgique 1	Antalgique 2	di	di <sup>2</sup>
1	260	250	+10	100
2	248	240	+8	64
3	270	240	+30	900
4	320	310	+10	100
5	270	240	+30	900
6	310	210	+100	10 000
7	332	260	+72	5184
8	240	290	-50	2500
9	250	260	-10	100
10	380	220	+160	25600
11	290	330	-40	1600
12	220	210	+10	100
13	280	300	-20	400
14	400	380	+20	400
15	370	300	+70	4900
16	284	230	+54	296
17	340	220	+120	14400
Totaux :			574	70 164

**Sous  $H_0$ ,**

$$t_c = \frac{\bar{d} - 0}{\frac{s_d}{\sqrt{n}}}$$

$$\bar{d} = \frac{\sum di}{N} = \frac{574}{17} = 33,76$$

$$s_d^2 = \frac{70\,164}{16} - \frac{574^2}{16 \cdot 17} = 3\,173,94$$

$$s_d = 56,34$$

$$t_c = 2,47$$

$$\alpha = 5\% \rightarrow t_t = 2,12$$

$t_c > t_t$  donc au risque 5% il existe une  $\neq$  significative d'efficacité entre les 2 antalgiques

$$\alpha = 1\% \rightarrow t_t = 2,92$$

$t_c < t_t$  donc au risque 1% on ne montre pas de  $\neq$  significative d'efficacité entre les 2 antalgiques



**Avec Wilcoxon :**

Rangs - = 31

Rangs + = 122

$\alpha = 5\% \rightarrow R \text{ table} = 35$

$R_C = \min(R^-; R^+) = 31$

$R \text{ table} > R_C$  : au risque 5%, on conclue à une différence significative

$\alpha = 1\% \rightarrow R \text{ table} = 23$

$R_C = \min(R^-; R^+) = 31$

$R \text{ table} < R_C$  : au risque 5%, on ne montre pas de différence significative